



Final Project

การศึกษาปัจจัยที่มีผลต่อความเครียดของนักศึกษาวิศวกรรมคอมพิวเตอร์ มจร.

Identifying factors affecting stress levels among Computer Engineering students at KMUTT

คณะผู้จัดทำ

นางสาวกัญญวรรณ	ทยานิพันธ์	66070501004
นางสาวกัลยา	สุทธปัญญา	66070501005
นางสาวจิรพรรณ	ศักดิ์พิสุทธิพงศ์	66070501009
นางสาวเปมิกา	จงขวัญยืน	66070501034
นางสาวศิริประภา	ชินวงษ์ทัน	66070501055
นายกัณฑ์ดนัย	ศรีวัฒน์นะ	65070507203
นายญาณภัทร	พึงแสงธรรมเลิศ	65070507231

เสนอ

ดร. สัณณูศิริ ธารประดับ

ภาคเรียนที่ 2 ปีการศึกษา 2567

รายวิชา CPE 232 แบบจำลองข้อมูล (Data Models)

ภาควิชาวิศวกรรมคอมพิวเตอร์ คณะวิศวกรรมศาสตร์

มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

สารบัญ

ชื่อเรื่อง	หน้า
Introduction	1
วัตถุประสงค์.....	1
รายละเอียดการเก็บข้อมูลโดย Google Form.....	2
Preprocessing.....	4
1. Import Libraries ที่จำเป็น.....	4
2. Import ข้อมูล.....	4
3. ตรวจสอบภาพรวมของข้อมูล	4
4. ลบและแปลงคอลัมน์ที่ไม่จำเป็น.....	4
5. แปลงข้อความที่เป็นช่วงเวลา หรือคำอธิบายให้เป็นตัวเลข	4
6. แปลงข้อมูลให้อยู่ในรูปแบบตัวเลขทศนิยม (Float)	5
7. แปลงข้อมูลจากข้อความลำดับ (Ordinal) ให้เป็นตัวเลข (Ordinal Encoding).....	5
8. แปลงข้อมูลประเภท Binary และการจัดลำดับอื่น ๆ.....	6
9. จัดการกับ Missing Data (ค่าที่ขาดหาย).....	6
10. ตรวจสอบภาพรวมของข้อมูลอีกครั้ง.....	6
สรุปขั้นตอนการ preprocessing	7
Exploratory Data Analysis (EDA)	8
1. Import Libraries	8
2. Load Dataset.....	8
3. ตรวจสอบและปรับปรุงข้อมูล	8
4. วิเคราะห์ข้อมูล	8
5. สรุปข้อมูลที่ได้จากการ EDA.....	9
6. ส่งต่อข้อมูล.....	12
สรุปกระบวนการ EDA.....	12

Method	13
Model Selection	13
Training & Evaluation	13
การวิเคราะห์ผล (Result Analysis)	16
Result & Discussion	17
ผลการศึกษา (Results)	17
การอภิปรายผล (Discussion)	19
Conclusion.....	25
ภาคผนวก ก.....	ก
ภาคผนวก ข	ข

Introduction

ปัญหาความเครียดในหมู่นักศึกษาระดับมหาวิทยาลัยถือเป็นประเด็นสำคัญที่ส่งผลต่อสุขภาพจิต สมรรถภาพทางการศึกษา และคุณภาพชีวิตโดยรวม โดยเฉพาะในสาขาวิชาที่มีการแข่งขันสูงและความกดดันจากภาระงานวิชาการ เช่น สาขาวิศวกรรมคอมพิวเตอร์ นักศึกษามักเผชิญกับความกดดันจากงานที่ได้รับมอบหมาย โครงการกลุ่ม ความคาดหวังทางวิชาการ ตลอดจนการปรับตัวต่อเทคโนโลยีที่เปลี่ยนแปลงอย่างรวดเร็ว ซึ่งอาจนำไปสู่ความเครียดสะสม

งานศึกษานี้จัดทำขึ้นภายใต้รายวิชา CPE232 DATA MODELS ภาคการศึกษา 2/2567 เพื่อวิเคราะห์และระบุปัจจัยที่มีผลต่อระดับความเครียดของนักศึกษาวิศวกรรมคอมพิวเตอร์ มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี (มจธ.) โดยใช้ข้อมูลจากแบบสอบถาม Google Form และนำไปประมวลผลในเชิงสถิติและการวิเคราะห์ข้อมูล เพื่อหาความสัมพันธ์ระหว่างตัวแปรต่าง ๆ กับระดับความเครียดของนักศึกษาและนำไปสู่การวิเคราะห์และสร้างแบบจำลองข้อมูลที่มีประสิทธิภาพอีกทั้งยังสามารถนำไปใช้ในการพัฒนามาตรการสนับสนุนนักศึกษาในอนาคต

วัตถุประสงค์

1. เพื่อระบุปัจจัยที่มีผลต่อระดับความเครียดของนักศึกษาวิศวกรรมคอมพิวเตอร์ มจธ. ในมิติต่าง ๆ ได้แก่ ปัจจัยด้านประชากรศาสตร์ การศึกษา พฤติกรรมการใช้ชีวิต และสุขภาพจิตและสังคม
2. เพื่อเก็บรวบรวมข้อมูลที่ครอบคลุมและเชื่อถือได้โดยใช้แบบสอบถาม Google Form ซึ่งออกแบบมาเพื่อประเมินความเครียดผ่านเครื่องมือมาตรฐาน ST-5 และตัวแปรอื่น ๆ ที่เกี่ยวข้อง
3. เพื่อนำข้อมูลที่ได้ไปใช้ในการสร้างแบบจำลองข้อมูลที่สามารถวิเคราะห์ความสัมพันธ์ระหว่างปัจจัยต่าง ๆ กับระดับความเครียด เพื่อเป็นพื้นฐานสำหรับงานวิจัยและการพัฒนามาตรการสนับสนุนนักศึกษา

รายละเอียดการเก็บข้อมูลโดย Google Form

การเก็บข้อมูลสำหรับการศึกษานี้ใช้ Google Form เป็นเครื่องมือหลัก โดยแบบสอบถามได้รับการออกแบบอย่างรอบคอบเพื่อให้ครอบคลุมข้อมูลที่จำเป็นสำหรับการวิเคราะห์ปัจจัยที่มีผลต่อความเครียดของนักศึกษาวิศวกรรมคอมพิวเตอร์ มจร. จำนวนผู้ตอบแบบสอบถามทั้งหมด 102 คน ซึ่งระยะเวลาการเก็บข้อมูลอยู่ระหว่างวันที่ 19 เมษายน พ.ศ. 2568 และ วันที่ 3 พฤษภาคม พ.ศ. 2568 รายละเอียดของการเก็บข้อมูลมีดังนี้

- โครงสร้างของแบบสอบถาม (ดูภาคผนวก ก)

แบบสอบถามประกอบด้วย 5 ส่วน รวมทั้งสิ้น 26 คำถาม ได้แก่

- ส่วนที่ 1: ข้อมูลด้านประชากรศาสตร์รวบรวมข้อมูลพื้นฐาน เช่น รหัสนักศึกษา ซึ่งบ่งบอกระดับชั้นปี และหลักสูตรที่กำลังศึกษา และเพศเพื่อวิเคราะห์ความแตกต่างของระดับความเครียดในกลุ่มประชากรที่หลากหลาย
- ส่วนที่ 2: ปัจจัยทางการศึกษาครอบคลุมข้อมูลเกี่ยวกับภาระงานวิชาการ ความยากของวิชาเรียน และความคาดหวังในผลการเรียน ซึ่งอาจเป็นปัจจัยสำคัญที่ก่อให้เกิดความเครียด
- ส่วนที่ 3: พฤติกรรมการใช้ชีวิตสำรวจพฤติกรรม เช่น การนอน การออกกำลังกาย การทานอาหาร และการใช้สื่อสังคมออนไลน์ ซึ่งอาจส่งผลต่อสุขภาพจิต
- ส่วนที่ 4: สุขภาพจิตและสังคมเก็บข้อมูลเกี่ยวกับความสัมพันธ์กับเพื่อน ครอบครัว รวมถึงการเงินที่อาจก่อให้เกิดความเครียด
- ส่วนที่ 5: ตัวแปรเป้าหมาย (Label) ใช้แบบประเมินความเครียด ST-5 ซึ่งพัฒนาโดยกรมสุขภาพจิต กระทรวงสาธารณสุข เพื่อวัดระดับความเครียดผ่านอาการต่าง ๆ เช่น การนอนไม่หลับ ความหงุดหงิด สมาธิสั้น ความเบื่อหน่าย และการแยกตัวจากสังคม ผลจากส่วนนี้จะถูกใช้เป็นตัวแปรเป้าหมายในการสร้างแบบจำลองข้อมูล

- วัตถุประสงค์ของการเก็บข้อมูล

ข้อมูลที่รวบรวมผ่าน Google Form จะถูกใช้เพื่อวัตถุประสงค์ทางการศึกษาในรายวิชา CPE232 DATA MODELS ภาคการศึกษา 2/2567 เท่านั้น โดยมีเป้าหมายเพื่อศึกษาความสัมพันธ์ระหว่างปัจจัยต่าง ๆ และระดับความเครียดของนักศึกษา ข้อมูลทั้งหมดจะถูกเก็บรักษาเป็นความลับและไม่มีการเปิดเผยข้อมูลส่วนบุคคล

- วิธีการเก็บข้อมูล

- ช่วงเวลาการเก็บข้อมูล: ผู้ตอบแบบสอบถามได้รับคำแนะนำให้กรอกข้อมูลในช่วงเวลาปกติที่ไม่ใช่ช่วงสอบ เพื่อให้ได้ข้อมูลที่สะท้อนถึงสถานการณ์ทั่วไปและหลีกเลี่ยงความคลาดเคลื่อนจากความเครียดในช่วงสอบ
- การรักษาความลับ: ข้อมูลส่วนบุคคลทั้งหมดจะถูกเก็บรักษาด้วยความปลอดภัยและใช้เพื่อวัตถุประสงค์ทางวิชาการเท่านั้น
- เครื่องมือที่ใช้: แบบประเมิน ST-5 เป็นเครื่องมือคัดกรองมาตรฐานที่เชื่อถือได้ ซึ่งช่วยให้สามารถวัดระดับความเครียดได้อย่างเป็นระบบและเป็นที่ยอมรับในระดับสากล

- การนำข้อมูลไปใช้

ข้อมูลที่รวบรวมได้จะถูกนำไปวิเคราะห์เพื่อหาความสัมพันธ์ระหว่างปัจจัยต่าง ๆ กับระดับความเครียด โดยใช้เทคนิคการวิเคราะห์ข้อมูลและการสร้างแบบจำลองในรายวิชา CPE232 ผลจากการวิเคราะห์จะช่วยให้เข้าใจถึงปัจจัยที่สำคัญที่สุดที่ส่งผลต่อความเครียดของนักศึกษา และสามารถนำไปสู่การพัฒนามาตรการหรือแนวทางในการลดความเครียดในอนาคต

Preprocessing

เนื่องจากแบบสอบถามถูกออกแบบมาอย่างดีในเชิงโครงสร้าง โดยเฉพาะการกำหนดช่วงคำตอบที่ชัดเจนและจำกัดช่วงอย่างเหมาะสม ซึ่งช่วยให้การเตรียมข้อมูลมีความสะดวกและลดความคลาดเคลื่อนของข้อมูลที่ได้ ขั้นตอนที่ใช้ในการ preprocess ข้อมูลมีดังนี้

1. Import Libraries ที่จำเป็น

ในขั้นแรก import ไลบรารีที่จำเป็นในการจัดการและวิเคราะห์ข้อมูล ได้แก่ numpy ใช้จัดการกับข้อมูลเชิงตัวเลข pandas ใช้จัดการกับข้อมูลในลักษณะตาราง (DataFrame) และ sklearn.preprocessing เพื่อแปลงค่าข้อความเป็นตัวเลข

2. Import ข้อมูล

เราทำการอ่านไฟล์ .csv ซึ่งเป็นผลลัพธ์ที่ได้จาก Google Form มาเก็บไว้ในรูปแบบของ DataFrame ด้วยคำสั่ง `pd.read_csv()` โดยตั้งชื่อว่า `df`

```
df = pd.read_csv('final_rawdata.csv')
```

3. ตรวจสอบภาพรวมของข้อมูล

ตรวจสอบชนิดข้อมูลและภาพรวมของ dataset ด้วยคำสั่ง `df.info()` ผลลัพธ์แสดงว่า dataset ประกอบด้วย 102 แถว และ 27 คอลัมน์ ในจำนวนนี้มี 14 คอลัมน์ที่มีชนิดข้อมูลเป็น object (string) ซึ่งจำเป็นต้องถูกแปลงให้เป็นข้อมูลเชิงตัวเลขเพื่อใช้งานในโมเดล Machine Learning ต่อไป

4. ลบและแปลงคอลัมน์ที่ไม่จำเป็น

1. ลบคอลัมน์ที่ไม่มีความสำคัญต่อการวิเคราะห์ เช่น Timestamp เพราะไม่ได้มีผลต่อพฤติกรรมที่ต้องการวิเคราะห์
2. เพิ่มคอลัมน์ “ชั้นปี” โดยดึงข้อมูล 2 ตัวแรกจากรหัสนักศึกษา ซึ่งเป็นรหัสประจำปีที่เข้าศึกษา และ map เป็นชั้นปี (เช่น รหัสขึ้นต้นด้วย 64 หมายถึงนักศึกษาชั้นปีที่ 2 ในปี 2025)

5. แปลงข้อความที่เป็นช่วงเวลา หรือคำอธิบายให้เป็นตัวเลข

แบบสอบถามมีการใช้ข้อความเพื่อแทนช่วงค่าบางช่วง เช่น “มากกว่า 40 ชั่วโมง” หรือ “ทุกมื้ออาหาร” ซึ่งไม่สามารถนำไปวิเคราะห์เชิงตัวเลขได้โดยตรง เราจึงทำการแปลงค่าดังกล่าวให้เป็นตัวเลขประมาณการณ เช่น

- “มากกว่า 40 ชั่วโมง” → 41
- “มากกว่า 12 วิชา” → 13
- “ทุกมื้ออาหาร” → 21 (อนุมานว่าหมายถึง 3 มื้อต่อวัน × 7 วัน)

- “วันละมากกว่า 3 แก้ว” → 28 (อนุมานว่าหมายถึง 4 แก้ว × 7 วัน)
- “วันละมากกว่า 3 ชั่วโมง” → 21 (อนุมานว่า 3 ชั่วโมง × 7 วัน)

โดยมีการใช้คำสั่ง `replace()`, `map()`, `to_numeric` ของ `pandas` และ `LabelEncoder` ของ `sklearn.preprocessing` เพื่อแปลงข้อความเหล่านี้ให้เป็นค่าตัวเลขตามสมมุติฐาน

6. แปลงข้อมูลให้อยู่ในรูปแบบตัวเลขทศนิยม (Float)

หลังจากทำการ `replace` ข้อความแล้ว เราทำการแปลงคอลัมน์ที่เกี่ยวข้อง เช่น “จำนวนชั่วโมงต่อสัปดาห์ที่ใช้ทำกิจกรรมอื่นนอกเหนือจากการเรียน” หรือ “จำนวนวิชาที่ลงทะเบียนเรียนในเทอมปัจจุบัน” ให้กลายเป็นชนิด `float` ด้วย `pd.to_numeric()` เพื่อให้สามารถนำไปใช้ในโมเดล `Logistic Regression` ซึ่งรองรับเฉพาะข้อมูลเชิงตัวเลข

7. แปลงข้อมูลจากข้อความลำดับ (Ordinal) ให้เป็นตัวเลข (Ordinal Encoding)

บางคำตอบในแบบสอบถามอยู่ในรูปแบบของลำดับชั้น (ordinal scale) เช่น ความพึงพอใจ หรือการประเมินตนเอง ซึ่งสามารถแปลงเป็นตัวเลขได้ตามลำดับความสูง-ต่ำ เช่น

ตัวอย่าง:

- GPAX:
 - “มากกว่า 3.6” → 1
 - “3.1 - 3.5” → 2
 - “2.6 - 3.0” → 3
 - “2.0 - 2.5” → 4
 - “ต่ำกว่า 2.0” → 5
- ระยะเวลาการนอน:
 - “น้อยกว่า 4 ชั่วโมง” → 1
 - “4-5 ชั่วโมง” → 2
 - “6-7 ชั่วโมง” → 3
 - “มากกว่า 7 ชั่วโมง” → 4
- ความถี่ในการออกกำลังกาย:

- “ไม่ออกเลย” $\rightarrow 1$
- “น้อยกว่า 1 ครั้งต่อสัปดาห์” $\rightarrow 2$
- “1-2 ครั้งต่อสัปดาห์” $\rightarrow 3$
- “3-5 ครั้งต่อสัปดาห์” $\rightarrow 4$
- “มากกว่า 5 ครั้งต่อสัปดาห์” $\rightarrow 5$
- การใช้โซเชียลมีเดีย:
 - “ไม่เล่นเลย” $\rightarrow 0$
 - “วันละไม่เกิน 1 ชั่วโมง” $\rightarrow 1$
 - “วันละ 1 - 3 ชั่วโมง” $\rightarrow 2$
 - “วันละ 4 - 6 ชั่วโมง” $\rightarrow 3$
 - “มากกว่า 6 ชั่วโมง” $\rightarrow 4$

8. แปลงข้อมูลประเภท Binary และการจัดลำดับอื่น ๆ

1. คอลัมน์ “เพศ”: ใช้ LabelEncoder แปลงเป็นค่าตัวเลข เช่น 0 = ชาย, 1 = หญิง
2. คอลัมน์ที่มีคำตอบแบบ Likert scale หรือความรู้สึก เช่น
 - a. ความรู้สึกไม่มีแรงจูงใจ
 - b. ความยากในการโฟกัส
 - c. ความอารมณ์แปรปรวน
 - d. การมองโลกในแง่ดี/ร้าย
3. ใช้ ordinal encoding เช่น 1 = น้อยที่สุด $\rightarrow$ 5 = มากที่สุด

9. จัดการกับ Missing Data (ค่าที่ขาดหาย)

ตรวจพบว่ามีค่าหายเพียง 1 ค่าในคอลัมน์ “ระดับความเครียดในช่วง 30 วันที่ผ่านมา” ซึ่งอาจเกิดจากการที่ผู้ตอบไม่ได้กรอกข้อมูล และไม่ได้ตั้งให้เป็นคำถามบังคับใน Google Form เราจึงใช้ค่าเฉลี่ยของคอลัมน์นั้นเติมลงไปแทนค่าที่ขาด

10. ตรวจสอบภาพรวมของข้อมูลอีกครั้ง

เพื่อให้แน่ใจว่าข้อมูลพร้อมสำหรับการวิเคราะห์:

- ใช้ `groupby()` เพื่อดูสัดส่วนของนักศึกษาในแต่ละชั้นปี
- ใช้ `describe()` เพื่อดูสถิติเบื้องต้น เช่น mean, std, min, max
- แบ่งกลุ่มข้อมูลตามชั้นปีเพื่อให้สามารถนำไปวิเคราะห์เชิงเปรียบเทียบได้

สรุปขั้นตอนการ preprocessing

หลังจากดำเนินขั้นตอนการ preprocessing ดังกล่าว ข้อมูลที่ได้มีความสะอาด ถูกต้อง และอยู่ในรูปแบบที่พร้อมสำหรับการนำไปสร้างโมเดล Machine Learning หรือการทำ Exploratory Data Analysis ต่อไป

Exploratory Data Analysis (EDA)

หลังจากการทำ Preprocessing ข้อมูลแล้ว จะนำข้อมูลที่ได้มาทำ Exploratory Data Analysis (EDA) ต่อ เพื่อทำความเข้าใจข้อมูลและเตรียมความพร้อมสำหรับการสร้างโมเดล Machine Learning ในขั้นตอนถัดไป

1. Import Libraries

มีการนำเข้าไลบรารีที่จำเป็นสำหรับการจัดการและวิเคราะห์ข้อมูล ได้แก่

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

เพื่อใช้ในการจัดการข้อมูล การแสดงผลในรูปแบบกราฟ และการวิเคราะห์ข้อมูลเชิงสถิติ

2. Load Dataset

ทำการโหลดชุดข้อมูลที่ผ่านการ Preprocessing แล้วจากไฟล์ CSV

```
df = pd.read_csv("final_cleaned_cpe_stress_data.csv")
```

3. ตรวจสอบและปรับปรุงข้อมูล

- ใช้ df.info() ตรวจสอบประเภทข้อมูล และ Missing Values
- เพิ่มคอลัมน์ SummaryST-5 ซึ่งรวมคะแนนจากแบบประเมินความเครียด ST-5 โดยใช้คำสั่ง

```
df['SummaryST-5'] = df['1. มีปัญหาการนอน...'] + df['2. มีสมาธิน้อยลง...'] + ...
```

- ในขั้นตอนนี้ได้เกิดปัญหาขึ้นก็คือ ชื่อคอลัมน์มีทั้งภาษาไทยและภาษาอังกฤษ ทำให้ชื่อคอลัมน์มีความยาวมากเกินไป ส่งผลให้การวิเคราะห์ข้อมูลเป็นไปด้วยความยุ่งยาก จึงได้ทำการเปลี่ยนชื่อคอลัมน์ให้สั้นลงและเป็นภาษาอังกฤษ เพื่อให้ง่ายต่อการวิเคราะห์ข้อมูลในขั้นตอนถัดไป

4. วิเคราะห์ข้อมูล

- วิเคราะห์ข้อมูลเชิงสถิติด้วย df.describe()
- สร้างกราฟแจกแจงข้อมูล ด้วยการใช้คำสั่ง sns.histplot(df[col], kde=True) เพื่อให้สามารถมองเห็นข้อมูลได้ชัดเจนยิ่งขึ้น
- สร้างกราฟ ด้วยการใช้คำสั่ง sns.boxplot(data=df, x=col, y='SummaryST-5') เพื่อให้ง่ายต่อการสอบตรวจสอบการกระจายตัวของข้อมูล

- วิเคราะห์ความสัมพันธ์ระหว่างข้อมูลด้วย heatmap ด้วยการใช้คำสั่ง

```
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm')
```


5. สรุปข้อมูลที่ได้จากการ EDA

- การวิเคราะห์ข้อมูลเชิงสถิติ ทำให้ทราบถึงค่าเฉลี่ย (Mean), ค่ามัธยฐาน (Median), ค่าสูงสุด/ต่ำสุด (Max/Min) การกระจายของข้อมูล ตัวอย่างเช่น


columns	count	mean	std	min	25%	50%	75%	max
Class hours per week (total courses)	102	18.980	5.056	0	18	21	22	27
Total courses registered	102	6.127	1.5458	2	6	6	6	13
Participation Hours per week	102	5.852	10.014	0	0	2	5.75	41
Extracurricular and self-study hours per week	120	4.911	5.559	0	1	4	7	31
SummaryST-5	102	7.509	3.013	0	5	8	10	15

ตัวอย่างค่าทางสถิติที่ได้


การแสดงผลในรูปแบบกราฟ ทำให้ทราบถึงข้อมูลโดยรวมของแต่ละคอลัมน์ ตัวอย่างเช่น




กราฟแสดง Class hours per week (total courses)



กราฟแสดง Total courses registered




กราฟแสดง Participation Hours per week



กราฟแสดง Extracurricular and self-study hours per week

- การตรวจสอบการกระจายตัวของข้อมูล พบว่ามี outlier บางส่วน ซึ่งเป็นจำนวนที่น้อยมาก ซึ่งไม่มีผลต่อโมเดลที่เราใช้เทรนข้อมูล
- นอกจากนี้กราฟยังแสดงให้เห็นถึงแนวโน้มความเครียดของผู้ที่เข้ามาทำแบบสอบถาม ซึ่งแนวโน้มส่วนใหญ่จะเป็นความเครียดในระดับกลางไปถึงระดับสูง จึงต้องมีการ การสร้างโมเดล Machine Learning เพื่อศึกษาปัจจัยที่มีผลต่อความเครียด



กราฟแสดง SummaryST-5

- การวิเคราะห์ความสัมพันธ์ระหว่างของข้อมูล ทำให้ได้ค่า correlation มาดังนี้



Heatmap ที่แสดงข้อมูลถึงความสัมพันธ์ของคอลัมน์ต่าง ๆ ต่อกอลัมน์ SummaryST-5

นอกจากมีการวิเคราะห์อื่น ๆ ดังที่แสดงในภาคผนวก ข ได้แก่

- การกระจายตัวของชั้นปีการศึกษา
- การกระจายตัวของเกรดเฉลี่ยสะสม
- การกระจายตัวของเพศ
- ชั่วโมงการนอนหลับต่อวันเทียบกับคะแนน ST-5
- จำนวนวันที่ออกกำลังกายต่อสัปดาห์เทียบกับคะแนน ST-5
- ชั่วโมงการใช้โซเชียลมีเดียต่อวันเทียบกับคะแนน ST-5
- จำนวนมื้ออาหารที่รับประทานตามรูปแบบการควบคุมอาหารต่อสัปดาห์เทียบกับคะแนน ST-5

- คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่องสมดุลระหว่างงาน/การเรียนรู้ กับชีวิตส่วนตัวช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5
- คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่องการมีคนให้พึ่งพาได้ในช่วง 30 วันที่ เทียบกับคะแนน ST-5
- คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่องความเครียดทางการเงินในช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5
- คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่องการมีปัญหาความสัมพันธ์ในช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5

6. ส่งต่อข้อมูล

ส่งออกผลลัพธ์จากการวิเคราะห์เพื่อให้ง่ายต่อการนำไปใช้งานต่อในขั้นตอนถัดไป

- กราฟต่างๆ ถูกบันทึกเป็นไฟล์ .png
- ค่าทางสถิติจากคำสั่ง `df.describe()` ส่งออกเป็น .csv ด้วยคำสั่ง `df.describe().to_csv('summary_statistics.csv')`

สรุปกระบวนการ EDA

กระบวนการ EDA ที่ดำเนินการนี้ช่วยให้เข้าใจข้อมูลได้ดีขึ้น ช่วยให้สามารถคัดเลือกฟีเจอร์ที่เหมาะสม รวมทั้งเตรียมความพร้อมของข้อมูลเพื่อใช้ในการสร้างโมเดล Machine Learning อย่างมีประสิทธิภาพในขั้นตอนถัดไป

Method

Model Selection

1. โมเดลที่เลือกใช้

Random Forest Classifier

2. เหตุผลที่เลือกใช้โมเดลนี้ เพราะ

- Random Forest มีความสามารถในการจัดการกับข้อมูลที่มีหลายมิติ และลดความเสี่ยงจาก overfitting ได้ดี
- สามารถจัดการกับปัญหาความไม่สมดุลของคลาส (class imbalance) ได้โดยใช้ `class_weight=balanced`
- มีความยืดหยุ่นและประสิทธิภาพสูงสำหรับข้อมูลที่มีความซับซ้อน
- มีการพิจารณา Logistic Regression และ Decision Tree ด้วย แต่ Random Forest มีความเหมาะสมมากกว่าจากการทดลองที่ผ่านมา

3. การปรับพารามิเตอร์ (Hyperparameter Tuning):

- ใช้ Optuna เพื่อค้นหาค่าพารามิเตอร์ที่ดีที่สุด
- พารามิเตอร์ที่ปรับ ได้แก่:
 - `n_estimators`
 - `max_depth`
 - `min_samples_split`
 - `min_samples_leaf`
 - `max_features`
 - `bootstrap`
 - `class_weight`
- ใช้คะแนน F1-weighted ในการประเมินความแม่นยำระหว่าง tuning

Training & Evaluation

1. วิธีการฝึกโมเดล:

- ใช้ SMOTE เพื่อแก้ปัญหาคลาสไม่สมดุลก่อนแบ่งข้อมูล
- แบ่งข้อมูลเป็น train/test (80/20) โดย stratified sampling

- ใช้ StratifiedKFold ร่วมกับ cross_val_score เพื่อประเมินแบบ cross-validation

2. เมตริกที่ใช้ในการประเมิน: Accuracy (ความแม่นยำ)

- Precision (ทำนายว่าเป็นคลาสนั้น แล้วถูกจริงกี่เปอร์เซ็นต์)
- Recall (จากทั้งหมดที่ควรเป็นคลาสนั้น โมเดลทำนายถูกกี่เปอร์เซ็นต์)
- F1-score (ค่าเฉลี่ยถ่วงน้ำหนักระหว่าง precision กับ recall)
- Confusion Matrix และ Classification Report

3. ผลลัพธ์ที่ได้จากโมเดล:

- ได้ค่า F1-score สูงสุดจาก cross-validation โดยใช้ Optuna
- บนชุดทดสอบ (Test Set):
 - Accuracy: (ค่าที่ print ออกมายังไม่ได้แสดงในผลลัพธ์ raw แต่สามารถเติมได้จากไฟล์จริง)
 - Precision, Recall, F1-score (แสดงผลด้วย classification_report)

- แสดงผล Confusion Matrix และ Feature Importance

```


Test Set Evaluation:
Accuracy: 0.5925925925925926
Precision: 0.5802469135802469
Recall: 0.5925925925925926
F1 Score: 0.5509077705156137

Classification Report:


```

	precision	recall	f1-score	support
0	0.60	0.86	0.71	7
1	0.67	1.00	0.80	6
2	0.67	0.29	0.40	7
3	0.40	0.29	0.33	7
accuracy			0.59	27
macro avg	0.58	0.61	0.56	27
weighted avg	0.58	0.59	0.55	27

ภาพไฟล์ ผลลัพธ์การ tuning



ภาพผลลัพธ์ Confusion Matrix



ภาพผลลัพธ์ Feature Importance

การวิเคราะห์ผล (Result Analysis)

- โมเดลทำงานดีในสถานการณ์ใด:
 - เนื่องจากใช้ SMOTE, โมเดลมีความสามารถในการทำนายคลาสที่มีจำนวนน้อยได้ดีขึ้น
 - การใช้ weighted metrics ช่วยให้การประเมินสอดคล้องกับคลาสไม่สมดุล
- การตรวจสอบความลำเอียง (Bias) หรือความแปรปรวน (Variance):
 - ใช้ cross-validation (StratifiedKFold) เพื่อลด bias จากการสุ่มข้อมูล
 - Random Forest ช่วยลด variance จากการใช้โมเดล decision tree เดียว

ข้อมูลเพิ่มเติม

- Optuna เป็น framework โอเพนซอร์สสำหรับการปรับไฮเปอร์พารามิเตอร์อัตโนมัติ ซึ่งออกแบบมาโดยเฉพาะสำหรับงานด้าน Machine Learning [1]
- SMOTE ย่อมาจาก Synthetic Minority Over-sampling Technique เป็นเทคนิคการโอเวอร์แซมปลิงที่ใช้เพื่อจัดการกับปัญหา ข้อมูลไม่สมดุล (imbalanced data) ในงานด้านการจำแนกประเภท classification ของ Machine Learning [2]

Result & Discussion

ผลการศึกษา (Results)

ประสิทธิภาพของโมเดล

โมเดล Random Forest ที่พัฒนาขึ้นสำหรับการทำนายระดับความเครียดแสดงประสิทธิภาพในระดับปานกลาง:

- ความแม่นยำโดยรวม (Accuracy): 59.3%
- Weighted Precision: 61.1%
- Weighted Recall: 59.3%
- Weighted F1 Score: 58.7%

ประสิทธิภาพแยกตามระดับความเครียด:

- Low Stressed (0): Precision 75%, Recall 43%, F1-score 55%, Support 7
- Medium Stressed (1): Precision 56%, Recall 83%, F1-score 67%, Support 6
- High Stressed (2): Precision 57%, Recall 57%, F1-score 57%, Support 7
- Very High Stressed (3): Precision 57%, Recall 57%, F1-score 57%, Support 7

ปัจจัยสำคัญที่มีอิทธิพลต่อระดับความเครียด

จากการวิเคราะห์คุณลักษณะด้วย Random Forest พบว่า 5 อันดับแรก ที่มีผลต่อการทำนายมากที่สุดคือ:

1. ความเครียดทางการเงิน (Financial Stress)
2. สมดุลระหว่างการเรียน/การทำงานและชีวิตส่วนตัว (Balance Between Work/Study and Personal Life)
3. จำนวนชั่วโมงเรียนต่อสัปดาห์ (Class hours per week)
4. ชั่วโมงกิจกรรมนอกหลักสูตรและการศึกษาด้วยตนเองต่อสัปดาห์ (Extracurricular and self-study hours)
5. มื้ออาหารต่อสัปดาห์/รูปแบบการรับประทานอาหาร (Meals per week)

ปัจจัยสำคัญระดับกลาง (อันดับ 6-10) ได้แก่:

- ปัญหาความสัมพันธ์ (Relationship Problems)
- การบริโภคคาเฟอีนหรือสารกระตุ้น (Caffeine or Stimulants Usage)
- ความรู้สึกว่ามีคนที่พึ่งพาได้ (Having Someone to Rely on)
- ชั่วโมงการมีส่วนร่วมในชั้นเรียนต่อสัปดาห์ (Participation Hours)
- ความรู้สึกเกี่ยวกับการเรียน (Feeling about studies)

ตัวแปรที่มีอิทธิพลน้อย (อันดับ 11-17) ได้แก่:

- การใช้สื่อสังคมออนไลน์ (Social Media Usage)
- ผลการเรียน (GPAX)
- จำนวนรายวิชาที่ลงทะเบียน (Total Courses)
- ความถี่ในการออกกำลังกาย (Exercise Frequency)
- ชั่วโมงการนอนต่อวัน (Sleep Hours)
- ปีการศึกษา (Academic Year)
- เพศ (Gender)

ความสัมพันธ์กับคะแนนความเครียด

จากการวิเคราะห์ความสัมพันธ์ (Correlation) กับคะแนน ST-5:

ความสัมพันธ์เชิงบวกที่แข็งแกร่งที่สุด (ปัจจัยที่สัมพันธ์กับความเครียดสูงขึ้น):

1. ความเครียดทางการเงิน ($r = 0.36$)
2. ปัญหาความสัมพันธ์ ($r = 0.33$)
3. ความรู้สึกเกี่ยวกับการเรียน ($r = 0.30$)

ความสัมพันธ์เชิงลบที่แข็งแกร่งที่สุด (ปัจจัยที่สัมพันธ์กับความเครียดต่ำลง):

1. สมดุลระหว่างการเรียน/การทำงานและชีวิตส่วนตัว ($r = -0.29$)
2. ปีการศึกษา ($r = -0.19$)
3. การมีคนพึ่งพาได้ ($r = -0.19$)
4. มีอาหารต่อสัปดาห์/รูปแบบการรับประทานอาหาร ($r = -0.11$)

การอภิปรายผล (Discussion)

การวิเคราะห์ Confusion Matrix

- กลุ่ม Medium Stressed (1) มีการทำนายที่แม่นยำที่สุด (5 จาก 6 กรณี)
- กลุ่ม Low Stressed (0) มีความท้าทายในการทำนายมากที่สุด โดยมีเพียง 3 จาก 7 กรณีที่ทำนายถูกต้อง
- มีความสับสนระหว่างกลุ่ม High Stressed (2) และ Very High Stressed (3) พอสมควร

ความสัมพันธ์ระหว่างความสำคัญของคุณลักษณะและค่าสหสัมพันธ์

1. ความเครียดทางการเงินและสมดุลชีวิต

- ความเครียดทางการเงินแสดงทั้งความสัมพันธ์สูงกับความเครียด ($r = 0.36$) และเป็นตัวทำนายที่สำคัญที่สุดในโมเดลการเรียนรู้ของเครื่อง
- สมดุลชีวิตการทำงาน-การเรียนรู้แสดงความสัมพันธ์เชิงลบที่แข็งแกร่ง ($r = -0.29$) และจัดอยู่ในอันดับที่สองของคุณลักษณะที่สำคัญที่สุด
- ผลลัพธ์เหล่านี้บ่งชี้อย่างสม่ำเสมอว่าปัจจัยทางเศรษฐกิจสังคมและความสมดุลในการใช้ชีวิตมีความสำคัญมากกว่าปัจจัยทางวิชาการล้วนๆ ในการทำนายระดับความเครียด

2. ภาระงานทางวิชาการ vs. ผลการเรียนรู้

- น่าสนใจที่โมเดลระบุว่าจำนวนชั่วโมงเรียนและกิจกรรมนอกหลักสูตร/การศึกษาด้วยตนเองเป็นตัวทำนายที่สำคัญมาก แม้ว่าจะมีความสัมพันธ์ค่อนข้างน้อย
- สิ่งนี้บ่งชี้ถึงความสัมพันธ์ที่ซับซ้อนและอาจไม่เป็นเชิงเส้นระหว่างการใช้เวลาและความเครียด
- ในทางตรงกันข้าม ผลการเรียนรู้จริง (GPAX) และชั้นปีการศึกษามีความสำคัญต่ำ แสดงว่าปริมาณงานมากกว่าคุณภาพของผลงานที่ขับเคลื่อนความเครียด

3. ปัจจัยด้านไลฟ์สไตล์และสุขภาพ

- รูปแบบการรับประทานอาหาร (มื้ออาหารต่อสัปดาห์) จัดอันดับที่ห้าในด้านความสำคัญแม้จะมีความสัมพันธ์ปานกลาง ($r = -0.11$)
- การบริโภคคาเฟอีน/สารกระตุ้นมีความสำคัญสูงกว่าที่คาดไว้เมื่อพิจารณาจากความสัมพันธ์ต่ำ

- การนอนหลับและการออกกำลังกายแสดงความสำคัญและความสัมพันธ์ต่อกับความเครียดอย่างสม่ำเสมอ
- ผลลัพธ์เหล่านี้บ่งชี้ว่าปัจจัยด้านไลฟ์สไตล์บางประการอาจมีผลกระทบแบบเกนท์หรือมีปฏิสัมพันธ์กับตัวแปรอื่นๆ ในแบบที่ไม่ถูกจับโดยความสัมพันธ์อย่างง่าย

4. พลวัตการสนับสนุนทางสังคม

- "การมีคนที่พึ่งพาได้" แสดงทั้งความสัมพันธ์ที่มีความหมาย ($r = -0.19$) และความสำคัญปานกลางของคุณลักษณะ
- ปัญหาความสัมพันธ์แสดงความสัมพันธ์สูง ($r = 0.33$) และความสำคัญปานกลาง
- สิ่งนี้ยืนยันความสำคัญของพลวัตทางสังคมในการจัดการความเครียดในกลุ่มนักศึกษา

5. ปัจจัยด้านประชากรศาสตร์และปัจจัยคงที่

- เพศและชั้นปีการศึกษาจัดอันดับต่ำสุดในด้านความสำคัญ แสดงว่าปัจจัยที่ขับเคลื่อนความเครียดเป็นปัจจัยตามสถานการณ์มากกว่าประชากรศาสตร์
- สิ่งนี้เน้นย้ำถึงประสิทธิผลที่อาจเกิดขึ้นของการแทรกแซงที่มีเป้าหมายโดยไม่คำนึงถึงลักษณะทางประชากรศาสตร์ของนักศึกษา

นัยสำคัญสำหรับการแทรกแซงและมาตรการช่วยเหลือ

1. การสนับสนุนด้านการเงินและการบริหารเวลา

- ควรให้ความสำคัญกับโปรแกรมความช่วยเหลือทางการเงิน เนื่องจากความเครียดทางการเงินมีทั้งความสัมพันธ์สูงและเป็นตัวทำนายที่สำคัญที่สุด
- การจัดอบรมเชิงปฏิบัติการด้านการบริหารเวลาที่เน้นสมดุลระหว่างการทำงานและชีวิตอาจมีประสิทธิภาพเป็นพิเศษ
- การจัดการภาระงานทางวิชาการดูเหมือนจะมีความสำคัญมากกว่าการแทรกแซงผลการเรียน

2. บริการสนับสนุนแบบบูรณาการ

- โมเดลชี้ให้เห็นว่าแนวทางแบบองค์รวมที่จัดการกับปัจจัยด้านการเงิน การบริหารเวลา และโภชนาการจะมีประสิทธิภาพมากที่สุด

- ความสำคัญสูงของปัจจัยหลายประการบ่งชี้ว่าการแทรกแซงที่เน้นเฉพาะด้านอาจมีผลกระทบจำกัด
- การระบุนักศึกษาที่มีปัจจัยเสี่ยงหลายประการตั้งแต่เนิ่นๆ อาจช่วยให้สามารถให้การสนับสนุนเชิงรุกได้

3. การทบทวนโปรแกรมวิชาการระดับภาควิชา

- การประเมินชั่วโมงเรียนและการกระจายภาระงานอาจเป็นประโยชน์มากกว่าการมุ่งเน้นที่มาตรฐานผลการเรียน
- ความสมดุลระหว่างเวลาเรียนในชั้นเรียนและข้อกำหนดการศึกษาด้วยตนเองควรได้รับความสนใจเป็นพิเศษ
- อาจพิจารณาการปรับโครงสร้างตารางการศึกษาเพื่อสนับสนุนสมดุลระหว่างการทำงานและชีวิตที่ดีขึ้น

4. การนำโมเดลไปประยุกต์ใช้และข้อจำกัด

- ประสิทธิภาพปานกลางของโมเดล (ความแม่นยำ 59.3%) ควรได้รับการพิจารณาเมื่อนำไปใช้ในระบบการทำนาย
- ความแตกต่างระหว่างความสัมพันธ์และความสำคัญของคุณลักษณะสำหรับตัวแปรบางตัวบ่งชี้ถึงความสัมพันธ์ที่ซับซ้อน
- การปรับปรุงโมเดลเพิ่มเติมอาจเน้นการสำรวจปฏิสัมพันธ์ระหว่างคุณลักษณะที่มีอันดับสูงสุด
- พิจารณาแนวทางแบบผสมผสานที่ใช้ประโยชน์จากทั้งจุดแข็งของความสัมพันธ์และข้อมูลเชิงลึกแบบไม่เชิงเส้นจากโมเดล Random Forest

ข้อจำกัดของการศึกษา

ขนาดตัวอย่างและกำลังทางสถิติ

- ขนาดตัวอย่างที่ค่อนข้างเล็ก (102 คน) จำกัดกำลังทางสถิติของการวิเคราะห์และความสามารถในการนำผลการศึกษาไปใช้กับประชากรทั่วไป
- จากข้อมูลเพียง 102 รายการที่แบ่งออกเป็นสี่กลุ่มระดับความเครียด ทำให้แต่ละกลุ่มมีตัวแทนจำกัด
- ขนาดตัวอย่างที่เล็กอาจมีส่วนทำให้ความแม่นยำของโมเดลอยู่ในระดับปานกลาง (59.3%)

- การศึกษาในอนาคตควรมุ่งเน้นที่ตัวอย่างขนาดใหญ่ขึ้นเพื่อปรับปรุงความเสถียรและประสิทธิภาพของโมเดล

ความไม่สมดุลของกลุ่มระดับความเครียด

- มีความไม่สมดุลอย่างมีนัยสำคัญระหว่างระดับความเครียดในชุดข้อมูลของเรา:
 - ความเครียดปานกลาง (Medium Stressed): 33 คน (32.4%)
 - ความเครียดสูงมาก (Very High Stressed): 28 คน (27.5%)
 - ความเครียดสูง (High Stressed): 25 คน (24.5%)
 - ความเครียดต่ำ (Low Stressed): 16 คน (15.7%)
- การมีตัวแทนน้อยของนักศึกษาที่มีความเครียดต่ำ (เพียง 15.7% ของตัวอย่าง) อาจจำกัดความสามารถของโมเดลในการระบุปัจจัยที่เกี่ยวข้องกับความเครียดต่ำได้อย่างแม่นยำ
- แม้จะใช้ SMOTE สำหรับการ oversampling ในระหว่างการฝึกโมเดล แต่ความไม่สมดุลในชุดข้อมูลเดิมอาจมีอิทธิพลต่อการคำนวณความสำคัญของคุณลักษณะ
- ความไม่สมดุลนี้อาจสะท้อนการกระจายความเครียดที่แท้จริงในกลุ่มนักศึกษาวิศวกรรมคอมพิวเตอร์ แต่ก็อาจบ่งชี้ถึงอคติในการสุ่มตัวอย่างหรือการเลือกตัวเองในกลุ่มผู้ตอบแบบสอบถาม

ความไม่สมดุลของการกระจายตัวของชั้นปีการศึกษา

- จากการวิเคราะห์ของเรา การกระจายตัวของนักศึกษาตามชั้นปีมีความไม่สมดุลอย่างมีนัยสำคัญ:
 - ชั้นปีที่ 2: 63 คน (61.8%)
 - ชั้นปีที่ 1: 17 คน (16.7%)
 - ชั้นปีที่ 3: 15 คน (14.7%)
 - ชั้นปีที่ 4: 7 คน (6.9%)
- แม้ว่าชั้นปีการศึกษาจะมีความสำคัญต่ำในโมเดลของเรา แต่การกระจายตัวที่ไม่สม่ำเสมอของผู้ตอบแบบสอบถามระหว่างชั้นปีต่างๆ ยังคงเป็นข้อจำกัดด้านวิธีการ
- การมีตัวแทนมากเกินไปของชั้นปีที่ 2 (61.8%) อาจบิดเบือนปัจจัยความเครียดหรือกลไกการรับมือที่เฉพาะเจาะจงกับชั้นปี

- นักศึกษาชั้นปีที่ 1 อาจเผชิญกับปัจจัยความเครียดที่แตกต่างกัน (การปรับตัวกับชีวิตมหาวิทยาลัย) เมื่อเทียบกับนักศึกษาชั้นปีสุดท้าย (การทำงาน ข้อกำหนดการสำเร็จการศึกษา)
- การวิเคราะห์เฉพาะชั้นปีถูกจำกัดโดยขนาดตัวอย่างที่ไม่เพียงพอภายในแต่ละกลุ่มชั้นปี

ปัญหาคุณภาพข้อมูล

- การมีค่า null เนื่องจากปัญหาในการออกแบบแบบสอบถามจำเป็นต้องมีการแทนที่ข้อมูลหรือลบแถว ซึ่งอาจทำให้เกิดอคติ
- ความผิดพลาดของมนุษย์ในการออกแบบแบบสำรวจเน้นย้ำถึงความสำคัญของการทดสอบแบบสอบถามอย่างละเอียดก่อนการนำไปใช้
- ความสามารถในการตรวจจับค่าผิดปกติหรือรูปแบบผิดปกติมีจำกัดเนื่องจากข้อจำกัดของขนาดตัวอย่าง

ข้อจำกัดด้านวิธีการ

- การออกแบบแบบตัดขวาง (cross-sectional) จับความเครียดเพียงจุดเดียวในช่วงเวลา ไม่สามารถแสดงความแปรปรวนตามเวลาของระดับความเครียดตลอดปีการศึกษา
- ข้อมูลที่รายงานด้วยตนเองในทุกตัวแปรอาจทำให้เกิดอคติในการรายงาน โดยเฉพาะสำหรับหัวข้อที่ละเอียดอ่อน เช่น ปัญหาความสัมพันธ์หรือผลการเรียน
- เครื่องมือประเมินความเครียด ST-5 แม้จะได้รับการตรวจสอบความถูกต้อง แต่ให้การวัดอย่างง่ายของปรากฏการณ์ทางจิตวิทยาที่ซับซ้อน
- การใช้ SMOTE oversampling มีความจำเป็นเพื่อแก้ไขความไม่สมดุลของคลาส แต่อาจแนะนำรูปแบบเทียมที่ไม่มีอยู่ในข้อมูลเดิม

ข้อจำกัดเฉพาะของโมเดล

- อัลกอริทึม Random Forest แม้จะมีประสิทธิภาพในการจับความสัมพันธ์แบบไม่เชิงเส้น แต่อาจ overfit กับชุดข้อมูลขนาดเล็ก
- ความแม่นยำปานกลางของโมเดล (59.3%) บ่งชี้ถึงความแปรปรวนที่ไม่ได้รับการอธิบายอย่างมากในระดับความเครียด
- ความสำคัญของคุณลักษณะใน Random Forests อาจได้รับอิทธิพลจากความสัมพันธ์ระหว่างตัวทำนาย ซึ่งอาจประเมินตัวแปรบางตัวสูงเกินไป

- การปรับ hyperparameter ด้วยข้อมูลจำกัดอาจไม่ได้ระบุพารามิเตอร์ที่เหมาะสมที่สุดอย่างแท้จริง

ทิศทางการวิจัยในอนาคต

1. การพัฒนาคุณลักษณะและศึกษาผลกระทบของการมีปฏิสัมพันธ์
 - สำรวจเงื่อนไขการมีปฏิสัมพันธ์ระหว่างตัวทำนายที่สำคัญ (เช่น ความเครียดทางการเงิน $\times$ สมดุลระหว่างการทำงานและชีวิต)
 - ตรวจสอบผลกระทบของเกณฑ์ที่อาจเกิดขึ้นในช่วงโรงเรียนและกิจกรรมนอกหลักสูตร
 - พัฒนาเกณฑ์วัดแบบผสมผสานที่อาจจับภาพความเป็นอยู่ที่ดีของนักศึกษาโดยรวมได้ดีขึ้น
2. พลวัตตามเวลาของความเครียด
 - การศึกษาระยะยาวเพื่อติดตามว่าปัจจัยความเครียดพัฒนาอย่างไรตลอดโปรแกรมการศึกษา
 - การตรวจสอบความแปรปรวนตามฤดูกาลในตัวทำนายความเครียด (ช่วงสอบ ช่วงต้นเทอมเทียบกับช่วงสิ้นเทอม)
3. การศึกษาประสิทธิผลของการแทรกแซง
 - การแทรกแซงที่มีเป้าหมายตามผลการค้นพบความสำคัญของคุณลักษณะระดับสูง
 - การศึกษาเปรียบเทียบของแนวทางการแทรกแซงปัจจัยเดียวเทียบกับหลายปัจจัย
 - มุ่งเน้นที่ปัจจัยที่มีผลกระทบสูงและอาจเปลี่ยนแปลงได้ เช่น ความรู้ทางการเงินและการบริหารเวลา
4. กลยุทธ์การปรับปรุงโมเดล
 - ทดลองกับวิธีการแบบ ensemble ที่รวมโมเดลตามความสัมพันธ์และโมเดลตามต้นไม้มัดตสันใจ
 - ทดสอบอัลกอริทึมทางเลือกที่อาจจับความสัมพันธ์ที่ซับซ้อนที่ระบุได้ดีขึ้น
 - ขยายชุดคุณลักษณะตามข้อมูลเชิงลึกจากโมเดลเริ่มต้นนี้

Conclusion

จากการศึกษาเพื่อวิเคราะห์ปัจจัยที่มีผลต่อระดับความเครียดของนักศึกษาวิศวกรรมคอมพิวเตอร์ มจร. พบว่าความเครียดของนักศึกษาไม่ได้เกิดจากปัจจัยใดปัจจัยหนึ่งเพียงอย่างเดียว แต่เป็นผลรวมของหลายมิติ ทั้งด้านเศรษฐกิจ สังคม การศึกษา และไลฟ์สไตล์ โดยเฉพาะความเครียดทางการเงินและความสมดุลระหว่างชีวิตส่วนตัวกับภาระทางการเรียนซึ่งเป็นปัจจัยที่มีอิทธิพลมากที่สุดต่อระดับความเครียด ผลการวิเคราะห์ข้อมูลเชิงสถิติร่วมกับโมเดล Random Forest ช่วยระบุลำดับความสำคัญของปัจจัยต่าง ๆ ได้อย่างชัดเจน และชี้ให้เห็นถึงความสำคัญของการสร้างสภาพแวดล้อมการเรียนรู้ที่สนับสนุนทั้งในด้านวิชาการและจิตใจ การค้นพบเหล่านี้สามารถนำไปประยุกต์ใช้ในการพัฒนานโยบายหรือมาตรการสนับสนุนนักศึกษาให้เหมาะสมยิ่งขึ้น ซึ่งอาจช่วยลดระดับความเครียดและส่งเสริมคุณภาพชีวิตของนักศึกษาได้อย่างยั่งยืนในอนาคต

Reference

- [1] Optuna Contributors, 2018, Optuna: A hyperparameter optimization framework, <https://optuna.readthedocs.io/en/stable/>, [8 พฤษภาคม 2568]
- [2] Rukchanok Piyapanichayakul, ปัญหาข้อมูลไม่สมดุล (Imbalanced Data in Classification Model), <https://ntcloudsolutions.ntplc.co.th/knowledge/imbalanced-data-classification/>, [8 พฤษภาคม 2568]

ภาคผนวก ก

โครงสร้างและคำถามในแบบสอบถาม

ส่วนที่ 1: ข้อมูลประชากรศาสตร์ (Demographic Information)

1. รหัสนักศึกษา (Student ID)
2. เพศ (Gender)

ส่วนที่ 2: ปัจจัยทางการศึกษา (Academic Factors)

1. ผลการเรียนเฉลี่ยสะสม หรือผลการเรียนโดยรวม (GPAX or Academic Performance)
2. จำนวนชั่วโมงเรียนต่อสัปดาห์ของวิชาทั้งหมดที่ลงทะเบียนในภาคการศึกษานี้ (Class hours per week)
3. จำนวนรายวิชาทั้งหมดที่ลงทะเบียนในภาคการศึกษานี้ (Total number of courses)
4. ชั่วโมงที่ใช้ในการเข้าร่วมกิจกรรมนอกหลักสูตรต่อสัปดาห์ (Extracurricular activities - Hours per week)
5. จำนวนชั่วโมงต่อสัปดาห์ที่เรียนเสริมนอกหลักสูตรและเรียนเสริมด้วยตนเอง ไม่รวมช่วงสอบ (Self-study/extra study - Hours per week)
6. ในช่วงที่ผ่านมา คุณรู้สึกเกี่ยวกับการเรียนของตัวเองอย่างไรบ้าง (Feelings about your studies recently)

ส่วนที่ 3: พฤติกรรมการใช้ชีวิต (Lifestyle Habits)

1. ชั่วโมงการนอนต่อวัน (Sleep Hours per Day)
2. จำนวนมื้ออาหารที่รับประทานตามรูปแบบการควบคุมอาหารต่อสัปดาห์ (Meals per week following a dietary pattern)
3. ความยากลำบากในการจดจ่อกับความคิดของตัวเอง (Difficulty focusing thoughts)
4. ความถี่ของการอารมณ์แปรปรวน (Mood swings frequency)
5. ออกกำลังกายกี่วันต่อสัปดาห์ (Exercise frequency)
6. การบริโภคคาเฟอีนหรือสารกระตุ้น - จำนวนแก้วต่อสัปดาห์ (Caffeine/stimulants - Cups per week)

7. การใช้โซเชียลมีเดีย - ชั่วโมงต่อวัน (Social media usage - Hours per day)

ส่วนที่ 4: สุขภาพจิตและสังคม (Psychological & Social Well-being)

1. ระดับความเครียดในช่วง 30 วันที่ผ่านมา (Self-reported stress level)
2. อาการวิตกกังวลหรือซึมเศร้าในช่วง 30 วันที่ผ่านมา (Anxiety/depression symptoms)
3. ปัญหาในความสัมพันธ์ในช่วง 30 วันที่ผ่านมา (Relationship problems)
4. ความเครียดทางการเงินในช่วง 30 วันที่ผ่านมา (Financial stress)
5. คุณรู้สึกว่าคุณมีคนที่สามารถพึ่งพาได้ในช่วง 30 วันที่ผ่านมาเพียงใด (Support availability)
6. ในช่วง 30 วันที่ผ่านมา คุณสามารถจัดสมดุลระหว่างงาน/การเรียนรู้ กับชีวิตส่วนตัวได้ดีแค่ไหน (Work-life balance)


ส่วนที่ 5: ตัวแปรเป้าหมาย (Label)

1. มีปัญหาการนอน นอนไม่หลับหรือนอนมาก (Trouble sleeping)
2. มีสมาธิน้อยลง (Difficulty concentrating)
3. หงุดหงิด/กระวนกระวาย/ว้าวุ่นใจ (Irritability/restlessness)
4. รู้สึกเบื่อ เซ็ง (Boredom/lack of interest)
5. ไม่อยากพบปะผู้คน (Avoiding social interactions)


[ลิงก์แบบสอบถาม](#)

ภาคผนวก ข


กราฟแสดงข้อมูลเพิ่มเติมในกระบวนการ EDA




การกระจายตัวของชั้นปีการศึกษา โดยเลข 1 - 2 หมายถึงนักศึกษาปี 1 - 4 ตามลำดับ




การกระจายตัวของเกรดเฉลี่ยสะสม




การกระจายตัวของเพศ โดย 0 = ชาย, 1 = หญิง และ 2 = อื่น ๆ




ชั่วโมงการนอนหลับต่อวันเทียบกับคะแนน ST-5




จำนวนวันที่ออกกำลังกายต่อสัปดาห์เทียบกับคะแนน ST-5




ชั่วโมงการใช้โซเชียลมีเดียต่อวันเทียบกับคะแนน ST-5




จำนวนมื้ออาหารที่รับประทานตามรูปแบบการควบคุมอาหารต่อสัปดาห์เทียบกับคะแนน ST-5




คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่อง สมดุลระหว่างงาน/การเรียนรู้ กับชีวิตส่วนตัวช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5



คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่อง
การมีคนให้พึ่งพาได้ในช่วง 30 วันที่ เทียบกับคะแนน ST-5



คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่อง
ความเครียดทางการเงินในช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5



คะแนนการประเมินตนเองของผู้ตอบแบบสอบถามช่วง 1 (คะแนนน้อยที่สุด) ถึง 10 (คะแนนมากที่สุด) เรื่อง
การมีปัญหความสัมพันธ์ในช่วง 30 วันที่ผ่านมา เทียบกับคะแนน ST-5